МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное
учреждение высшего образования
**«Южно-Уральский государственный университет
(национальный исследовательский университет)»**
**Институт естественных и точных наук**
**Кафедра системного программирования**

# ОТЧЕТ

о выполнение практической работы №2

по дисциплине

«Основы интеллектуального анализа данных»

Проверил:

доцент кафедры СП, к. ф.-м. наук

_____Б.А. Марков

Автор работы:
студент группы ЕТ-401

_____А.О. Жалий

Челябинск, 2026 г.

**ОГЛАВЛЕНИЕ**

1. ФОРМУЛИРОВКА ЗАДАНИЯ ..... 3
1.1. Классификация с помощью дерева решений ..... 3
2. ИСХОДНЫЙ КОД ..... 4
3. ТЕОРИЯ ..... 5
3.1. Построение деревьев решений ..... 5
3.2. Критерий ID3 – Information Gain ..... 5
3.3. Критерий C4.5 – Gain Ratio ..... 5
3.4. Критерий CART – Gini index ..... 6
4. РЕАЛИЗАЦИЯ ..... 7
4.1. Общая структура программы ..... 7
4.2. Реализация ID3 (Information Gain) ..... 7
4.3. Реализация C4.5 (Gain Ratio) ..... 7
4.4. Реализация CART (Gini index) ..... 8
4.5. Метрики качества ..... 8
5. РЕЗУЛЬТАТЫ ЭКСПЕРИМЕНТОВ ..... 9
5.1. Визуализация дерева решений ..... 9
5.2. Сравнение ID3 и C4.5 ..... 10
5.3. Сравнение C4.5 и CART ..... 11
6. ВЫВОДЫ ..... 12

# 1. ФОРМУЛИРОВКА ЗАДАНИЯ

## 1.1. Классификация с помощью дерева решений

Разработать программу, которая выполняет классификацию заданного набора данных с помощью дерева решений. Параметрами программы являются:

- набор данных;
- критерий выбора атрибута разбиения (Information gain, Gain ratio, Gini index).

Провести эксперименты на наборе Census Income (данные о результатах переписи населения, в т.ч. о годовом доходе – ниже или выше $50000). В качестве обучающей выборки для построения дерева использовать 100% исходных данных.

Выполнить визуализацию построенных деревьев решений.

Доработать программу, добавив в список параметров долю, которую занимает обучающая выборка от общего размера набора данных, и обеспечив вычисление и выдачу показателей качества классификации: accuracy, precision, recall, F-measure.

Провести эксперименты, фиксируя критерий разбиения и варьируя соотношение обучающей и тестовой выборок от 60%:40% до 90%:10% с шагом 10%.

Выполнить визуализацию:

- построенные деревья решений для заданного набора данных;
- показатели качества классификации в зависимости от соотношения мощностей обучающей и тестовой выборок.

Дополнительно требуется реализовать алгоритм построения дерева решений CART (Classification and Regression Trees), использующий индекс Джини (Gini index) в качестве критерия разбиения, и провести сравнительный анализ с реализациями ID3 и C4.5.

## 2. ИСХОДНЫЙ КОД

Исходный код (Python), результаты экспериментов и диаграммы доступны по ссылке: https://github.com/TWorkerFrog/FindTemplate

## 3. ТЕОРИЯ

### 3.1. Построение деревьев решений

Дерево решений – это модель классификации, которая последовательно задаёт вопросы о признаках объекта и по ответам приходит к классу. Каждый внутренний узел – проверка условия (например, education-num <= 12.5), каждая ветвь – исход проверки, каждый лист – предсказанный класс.

Построение дерева – жадный рекурсивный процесс сверху вниз:

1. Начать с корня – все данные в одном узле.
2. Выбрать лучший признак для разбиения по заданному критерию.
3. Разделить данные по этому признаку.
4. Рекурсивно повторить для каждого потомка.
5. Остановиться, когда узел чистый, данных мало или достигнута максимальная глубина.

### 3.2. Критерий ID3 – Information Gain

ID3 использует энтропию как меру неопределённости классов в узле:

$\text{Entropy}(S) = -\Sigma\, p_i \cdot \log_2(p_i)$.

Information Gain (прирост информации) показывает, насколько уменьшилась энтропия после разбиения по признаку A:

$\text{Gain}(S, A) = \text{Entropy}(S) - \Sigma\, (|S_v| / |S|) \cdot \text{Entropy}(S_v)$.

Дерево выбирает признак с максимальным Gain. Основной недостаток ID3 – он «любит» признаки с большим числом уникальных значений (например, ID клиента), которые дают идеальное разбиение, но бесполезны для предсказания.

### 3.3. Критерий C4.5 – Gain Ratio

Чтобы исправить недостаток ID3, C4.5 вводит Gain Ratio, нормируя Gain на «внутреннюю информацию» признака: $\text{SplitInfo}(S, A) = -\Sigma\, (|S_v| / |S|) \cdot \log_2(|S_v| / |S|)$, $\text{GainRatio}(S, A) = \text{Gain}(S, A) / \text{SplitInfo}(S, A)$.

Чем больше уникальных значений у признака, тем выше SplitInfo, тем сильнее штрафуется Gain. Дерево выбирает признак с максимальным Gain Ratio. Кроме того, C4.5 умеет работать с непрерывными признаками (через пороги), обрабатывать пропуски и делать pruning (обрезку).

### 3.4. Критерий CART – Gini index

CART использует индекс Джини – меру вероятности неправильно классифицировать случайно выбранный элемент: $Gini(S) = 1 - \Sigma p_i^2$.
Дерево выбирает признак, который сильнее всего уменьшает Gini. CART всегда строит бинарное дерево: каждый узел делится строго на две части по условию значение <= порог. CART работает быстрее ID3 и C4.5, так как не использует логарифмы.

# 4. РЕАЛИЗАЦИЯ

## 4.1. Общая структура программы

Программа реализована на языке Python. Для загрузки и предобработки данных используется pandas, для визуализации – matplotlib. Алгоритмы деревьев решений (ID3, C4.5, CART) реализованы вручную с использованием numpy; для сравнения также используется реализация DecisionTreeClassifier из scikit-learn.

Набор данных – Census Income (Adult). Обучающая и тестовая выборки объединяются в единый датасет, пропуски удаляются, категориальные признаки кодируются через LabelEncoder, целевая переменная income приводится к бинарному виду (0 – ≤50K, 1 – >50K).

Параметры программы: доля обучающей выборки, критерий разбиения, максимальная глубина дерева, минимальное число записей для разбиения.

## 4.2. Реализация ID3 (Information Gain)

В реализации ID3 на каждом шаге для каждого признака вычисляется Information Gain. Для непрерывных признаков перебираются пороги; вычисляется энтропия левого и правого подмножеств, взвешенная на их доли. Выбирается признак и порог с максимальным Gain.

## 4.3. Реализация C4.5 (Gain Ratio)

C4.5 построен аналогично ID3, но вместо Gain используется Gain Ratio. Для каждого разбиения вычисляются Gain и SplitInfo; их отношение – Gain Ratio. Дерево выбирает признак с максимальным Gain Ratio. Это штрафует признаки с большим числом уникальных значений и делает дерево устойчивее.

### 4.4. Реализация CART (Gini index)

CART реализован по той же схеме, но с индексом Джини. Для каждого разбиения вычисляется Gini до и после; выбирается разбиение с максимальным снижением Gini (Gini Gain). CART всегда делит узел на две части, что делает его проще и быстрее ID3 и C4.5.

### 4.5. Метрики качества

- Accuracy – доля правильных ответов: (TP + TN) / (TP + TN + FP + FN).
- Precision – точность: TP / (TP + FP).
- Recall – полнота: TP / (TP + FN).
- F1 – среднее гармоническое Precision и Recall.

Все метрики считаются для класса >50K (редкий класс, доля ~24%).

## 5. РЕЗУЛЬТАТЫ ЭКСПЕРИМЕНТОВ

### 5.1. Визуализация дерева решений

На рисунке 1 представлено дерево решений, построенное на обучающей выборке набора Census Income. Корневое разбиение происходит по признаку relationship (семейное положение). Далее дерево уточняет предсказание по уровню образования (education-num), приросту капитала (capital-gain) и возрасту (age).

В листьях с энтропией 0 модель абсолютно уверена в предсказании (например, узел с samples = 700 и class = >50K). В листьях с высокой энтропией классы смешаны, и предсказание менее надёжно. Дерево показывает, что для определения уровня дохода наиболее информативными оказались признаки, связанные с образованием, семейным положением и наличием инвестиционного дохода.

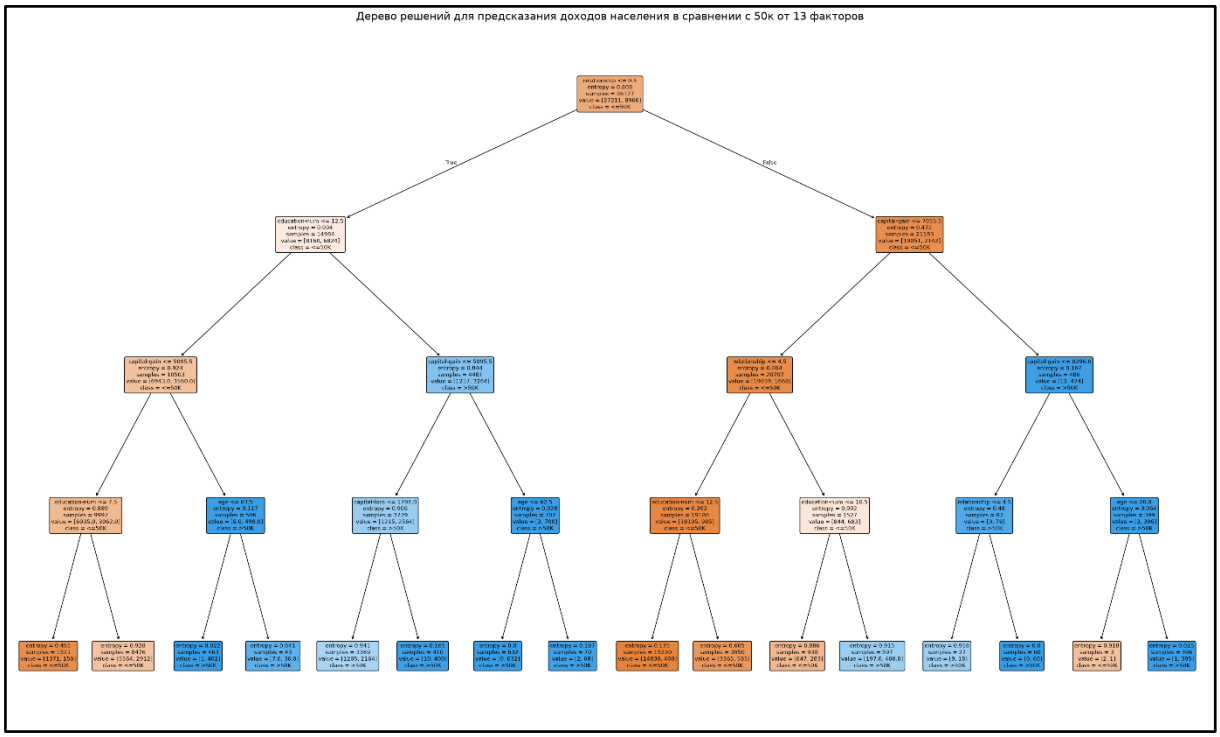



Рисунок 1 – Визуализация дерева решений для предсказания доходов населения

### 5.2. Сравнение ID3 и C4.5

На рисунке 2 приведено сравнение метрик качества для деревьев, построенных по критериям ID3 (Information Gain) и C4.5 (Gain Ratio), при различных соотношениях обучающей и тестовой выборок (от 60:40 до 90:10).

По графикам видно, что оба критерия дают близкие результаты. Метрики Accuracy и Precision практически совпадают на всех долях. Однако по метрикам Recall и F1-Score алгоритм ID3 немного превосходит C4.5 (например, при 80:20 F1 у ID3 составляет ~0.625, а у C4.5 – ~0.585).

Это объясняется тем, что C4.5 штрафует признаки с большим числом уникальных значений (через SplitInfo), а на Census Income такие признаки (например, capital-gain) оказываются очень информативными. Штраф снижает их приоритет, что в данном случае приводит к чуть менее точной модели. Кроме того, наша реализация C4.5 не выполняет pruning (обрезку дерева), что также влияет на качество.

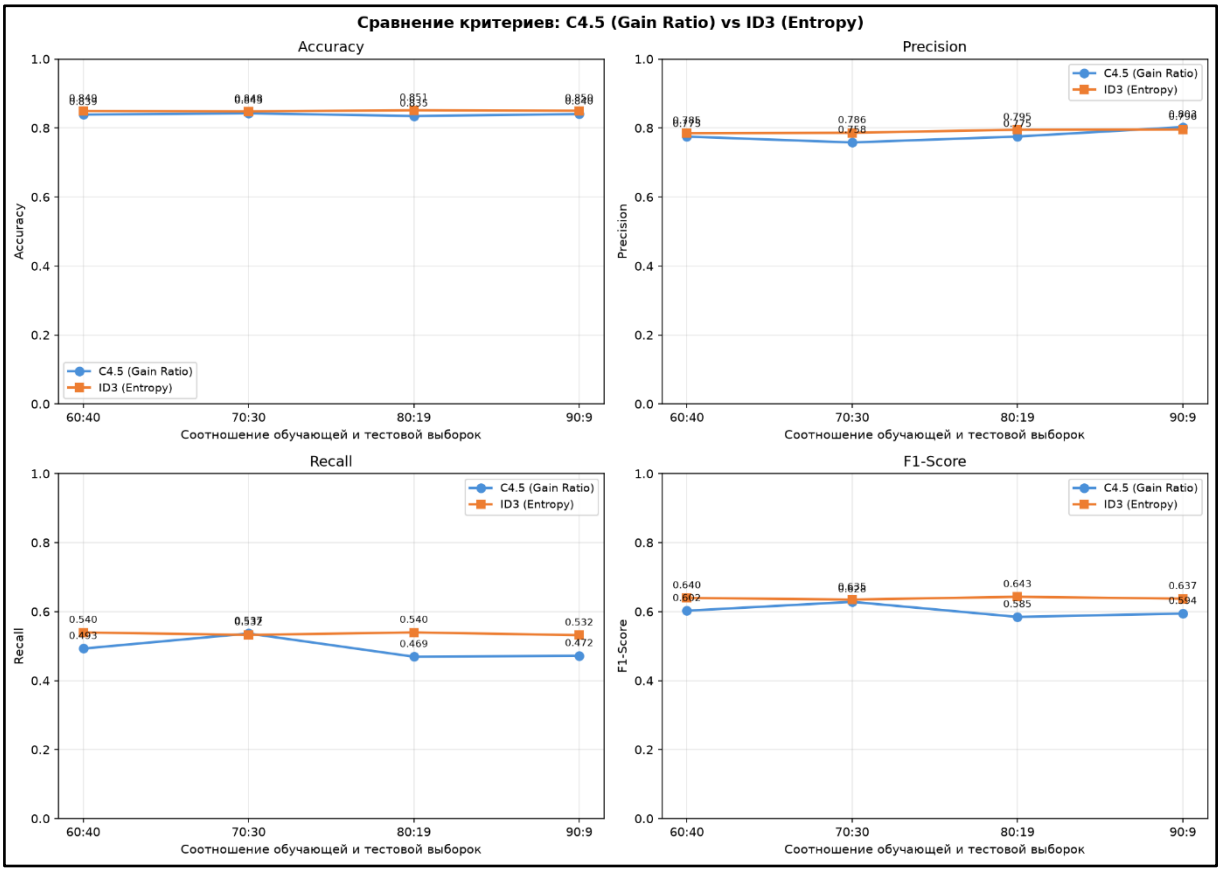



Рисунок 2 – Сравнение метрик качества ID3 (Information Gain) и C4.5 (Gain Ratio)

### 5.3. Сравнение C4.5 и CART

На рисунке 3 приведено сравнение C4.5 (Gain Ratio) и реализованного алгоритма CART (Gini index).

В отличие от предыдущего сравнения, здесь CART показывает себя значительно лучше. По метрикам Accuracy и Precision алгоритмы идут практически вровень. Однако по Recall и F1-Score CART стабильно опережает C4.5 на всех тестовых долях (например, при 80:20 F1 у CART составляет ~0.650, а у C4.5 – ~0.585).

Это связано с тем, что индекс Джини (CART) работает быстрее и часто лучше подходит для бинарной классификации на плотных числовых данных. CART не штрафует признаки за количество уникальных значений так агрессивно, как C4.5, и лучше находит закономерности в таких признаках, как capital-gain и age.

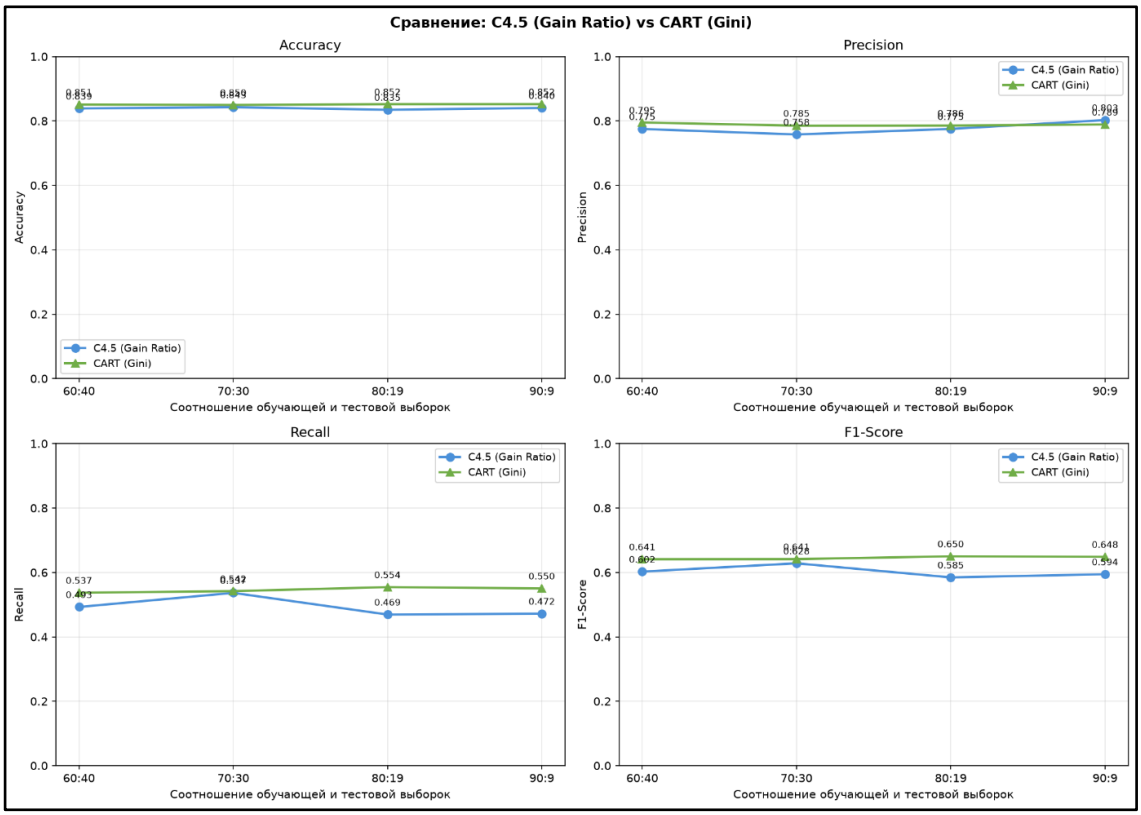



Рисунок 3 – Сравнение метрик качества C4.5 (Gain Ratio) и CART (Gini)

## 6. ВЫВОДЫ

В ходе работы были реализованы три алгоритма построения деревьев решений: ID3 (Information Gain), C4.5 (Gain Ratio) и CART (Gini index). Для каждого реализованы функции вычисления критерия, рекурсивное построение дерева и предсказание.

Эксперименты на наборе Census Income показали следующее:

- Наилучшее качество классификации достигается при соотношении обучающей и тестовой выборок 80:20.
- Алгоритм ID3 и CART показали наиболее высокие результаты по метрикам Recall и F1-Score. CART стабильно опережал C4.5 по этим метрикам на 3–5%.
- Алгоритм C4.5 незначительно уступил по Recall и F1. Это объясняется штрафом за многообразие значений признаков (Gain Ratio) и упрощённой реализацией без этапа pruning.

Каждый алгоритм имеет свои особенности:

- ID3 – прост в реализации, но «любит» признаки с большим числом значений.
- C4.5 – концептуально устойчивее к переобучению (за счёт штрафа Gain Ratio) и умеет работать с пропусками, но на данных Census Income его штраф снижает качество на информативных признаках.
- CART – строит бинарное дерево, работает быстрее (нет логарифмов) и на практике показал лучшие результаты по F1-мере.

Таким образом, для задачи предсказания дохода на Census Income оптимальным выбором среди рассмотренных одиночных деревьев является CART.